Redes Generativas Adversarias (GANs)

por Adrià Cabeza Sant'Anna

2020

Contenido

- Teoría
  - ¿Qué es una GAN?
  - Loss Function
  - Entrenamiento
- Autocolorizador
  - Generador
  - Discriminador
- Implementación en TF 2.0 [1]

Usos

Ejemplos de aplicaciones

- Superresolución e.g. `https://github.com/tensorlayer/SRGAN`
- Colorización e.g. `https://github.com/jantic/DeOldify`
- Síntesis de imágenes e.g. `https://www.thispersondoesnotexist.com/`
- Traducción de imágenes
- Aumentar el tamaño de datasets

- Más de 500 arquitecturas diferentes!! `https://github.com/hindupuravinash/the-gan-zoo`

Usos

Teoría

¿Qué es una GAN?

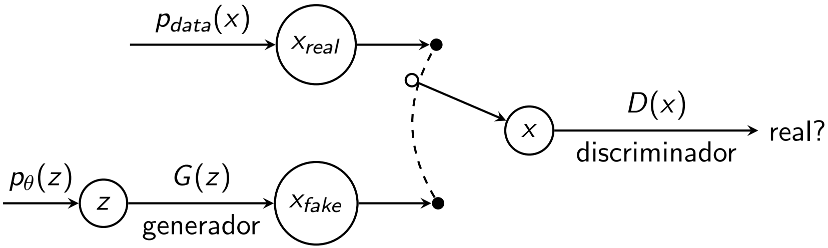

Adversarial Loss [2]

$\min_G \max_D V(D,G) =$
$\mathbb{E}_{\boldsymbol{x} \sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z} \sim p_{\boldsymbol{z}}}(\boldsymbol{z})[\log(1 - D(G(\boldsymbol{z})))]$

Loss Function

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}}(\boldsymbol{z})[\log(1 - D(G(\boldsymbol{z})))]$$

- D quiere maximizar la probabilidad de clasificar la data correctamente:
  - $\log D(\boldsymbol{x})$ es decir $D(x) \to 1$
  - $\log(1 - D(G(\boldsymbol{z})))$ es decir $D(G(z)) \to 0$
- G quiere minimizar esa probabilidad a D:
  - $\log(1 - D(G(\boldsymbol{z})))$ es decir $D(G(z)) \to 1$

Optimality

Si quereis saber más sobre porqué funciona la Loss function o sobre su *optimality* $\to$ Id a la diapositiva 15.

for 1 to N **do**

  for 1 to k **do**

    Cogemos $z^{(1)}, ..., z^{(m)} \in \mathrm{p}_g(z)$

    Cogemos $x^{(1)}, ..., x^{(m)} \in \mathrm{p}_{data}(x)$

    Actualizamos el discriminador usando stochastic gradient ascent/descent:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^{m} \left[\log D\left(\boldsymbol{x}^{(i)}\right) + \log\left(1 - D\left(G\left(\boldsymbol{z}^{(i)}\right)\right)\right)\right]$$

  end for

  Cogemos $z^{(1)}, ..., z^{(m)} \in \mathrm{p}_g(z)$

  Actualizamos el generador usando stochastic gradient ascent/descent:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^{m} \left[\log D\left(\boldsymbol{x}^{(i)}\right) + \log\left(1 - D\left(G\left(\boldsymbol{z}^{(i)}\right)\right)\right)\right]$$

end for

Memes

Ahora ya podéis entender los memes:

Autocolorizador: Pix2Pix [3]

Autocolorizador:Generador UNET

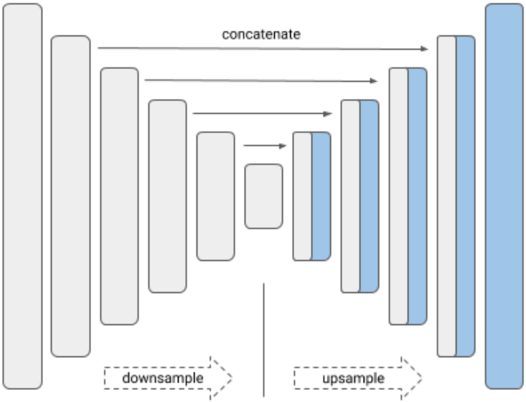

1x1	1x0	1x1	0	0
0x0	1x1	1x0	1	0
0x1	0x0	1x1	1	1
0	0	1	1	0
0	1	1	0	0

4		

Autocolorizado:Discriminador PatchGAN

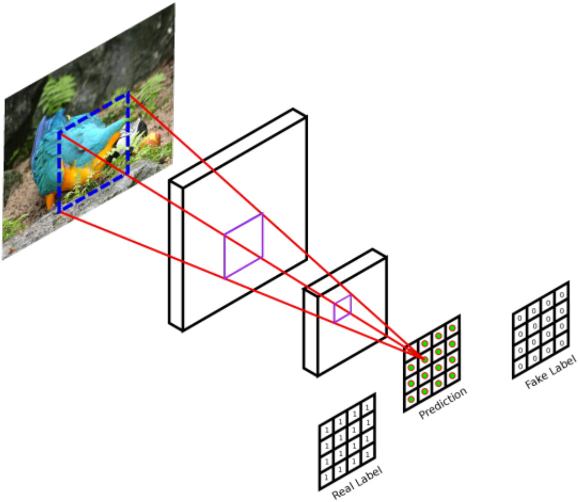

Implementación en TF 2.0

Let's start coding!

`https://github.com/adriacabeza/GAN-Workshop`

Bibliography

- "Tensorflow: A system for large-scale machine learning." `https://www.tensorflow.com/`.
- I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative adversarial networks," 2014.
- P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, "Image-to-image translation with conditional adversarial networks," 2016.

Optimality de una GAN

Como hemos mencionado anteriormente, la loss function de una GAN consiste en un juego minimax:

$$\begin{aligned}\min_G \max_D V(D, G) &= \mathbb{E}_{x \sim p_{data}(x)}[\log D(x)] + \mathbb{E}_{z \sim p_z(z)}[\log(1 - D(G(z)))] \\ &= \mathbb{E}_{x \sim p_{data}(x)}[\log D(x)] + \mathbb{E}_{x \sim p_g(x)}[\log(1 - D(x))] \\ &= \int_x [p_{data}(x) \log D(x) + p_g(x) \log(1 - D(x))] dx\end{aligned}$$

Interpretación del criterio de training para D

Nuestro objetivo es, dado cualquier generador G, maximizar la cantidad $V(D, G)$ de manera que puede ser interpetado como maximizar el log-likelihood de $P(Y = y|x)$, donde Y indica si x viene de p_{data} $(y = 1)$ o de p_g $(y = 0)$.

Para demostrar su optimality, primero analizaremos el discriminador óptimo D^*. Si partimos de la loss function teniendo en cuenta solo D, o sea fijando G:

$$p_{data}(x) \cdot \log D(x) + p_g(x) \cdot \log(1 - D(x))$$

podemos buscar su valor máximo (demostración en la próxima diapositiva) para encontrar a D*

$$D^* = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}$$

Para cualquier $(a, b) \in R^2 \setminus (0, 0)$ la función $f(x) = a \cdot log(x) + b \cdot log(1 - x)$ llega a su máximo en [0,1] en $\frac{a}{a+b}$.

$$f(x) = a \cdot log(x) + b \cdot log(1 - x)$$
$$f'(x) = \frac{a}{x} - \frac{b}{1 - x} = 0$$
$$\frac{a}{x} - \frac{b}{1 - x} = 0$$
$$a \cdot (1 - x) - b \cdot x = 0$$
$$x = \frac{a}{a + b}$$

sabiendo que $a + b \neq 0$, comprovamos que sea un máximo:

$$f''(x) = (a \cdot log(x) + b \cdot log(1 - x))'' = \frac{-a}{x^2} - \frac{b}{(1 - x)^2} < 0$$

Nótese que valor óptimo de D^* se consigue cuando $p_{data} = p_g$:

$$D^*(x) = \frac{p_{data}}{p_{data} + p_g} = \frac{1}{2}$$

Eso quiere decir que el discriminador no tiene ni idea de si la data es de $p_g(0)$ o de $p_{data}(1)$. Lo cual tiene sentido, es al fin y al cabo lo que queremos. Ahora pues ya podemos reemplazar ese valor en la loss function:

$$\min_G \max_D V(\frac{1}{2}, G) = \mathbb{E}_{x \sim p_{data}(x)} \left[\log \frac{1}{2} \right] + \mathbb{E}_{z \sim p_z(z)} \left[\log \left(1 - \frac{1}{2} \right) \right]$$
$$= -2 \log 2 = -\log 4$$

Ahora solo nos queda demostrar que el mínimo global de la loss function se consigue si y solo si $p_{data} = p_g$ y tiene de valor $-\log 4$.
Y eso lo dejo como deberes...

Si lo hacéis, tenéis mucha curiosidad o no os sale, no dudéis en escribirme a adriacabezasantanna@gmail.com.